

APRENDIZAJE POR REFUERZO

PRÁCTICA 2. APRENDIZAJE POR REFUERZO PROFUNDO

Aplicaciones

Máster en Investigación en Inteligencia Artificial, Universidad Internacional Menéndez Pelayo

Andrés García-Serra Romero
100012509@alumnos.uimp.es

13 de julio de 2026

Índice

1. Optimización de CartPole-v1	2
Descripción del entorno y objetivo	2
Política aleatoria de referencia	2
Elección y funcionamiento de DQN	3
Configuración Experimental	3
Evolución del entrenamiento	3
Evaluación final y comparación de políticas	4
Selección de la política y demostración visual	5
Conclusiones del experimento	6

1. Optimización de CartPole-v1

Descripción del entorno y objetivo

El primer ejercicio se desarrolló sobre *CartPole-v1*, un entorno de control clásico incluido en Gymnasium (Towers et al., 2024). El problema consiste en mantener en equilibrio un péndulo unido a un carro que puede desplazarse horizontalmente. En cada instante, el agente recibe una observación continua formada por cuatro variables:

1. Posición horizontal del carro
2. Velocidad horizontal del carro
3. Ángulo del péndulo
4. Velocidad angular del péndulo

El espacio de acciones es discreto y contiene dos posibilidades: aplicar una fuerza hacia la izquierda o hacia la derecha. El entorno proporciona una recompensa de +1 por cada paso en el que el episodio continúa. Por tanto, en este problema la recompensa acumulada coincide con la duración del episodio. La versión **CartPole-v1** finaliza como máximo tras 500 pasos, de modo que una política resuelve completamente el ejercicio cuando obtiene una recompensa de 500.

La Figura 1 resume el ciclo utilizado durante el entrenamiento y la evaluación. La observación se introduce en la red neuronal, que estima el valor de las dos acciones. La acción seleccionada se aplica al entorno, que devuelve el estado siguiente y la recompensa correspondiente.




Figura 1: Ciclo agente-entorno empleado en CartPole-v1.

Política aleatoria de referencia

Antes de entrenar el agente se evaluó una política aleatoria durante 30 episodios. Esta política selecciona una de las dos acciones mediante `action_space.sample()`, sin utilizar las cuatro variables que describen el estado. Su finalidad no es resolver el entorno, sino proporcionar una línea base con la que comprobar cuánto aporta el aprendizaje.

Para que la comparación fuese reproducible, cada episodio se inicializó con una semilla controlada y también se fijó la semilla del espacio de acciones. Los mismos 30 estados iniciales se utilizaron posteriormente para evaluar las políticas DQN. De esta forma, las diferencias de rendimiento no se deben a que cada política haya sido probada sobre condiciones iniciales distintas.

Elección y funcionamiento de DQN

Se escogió el algoritmo *Deep Q-Network* (DQN) (Mnih et al., 2015), utilizando la implementación de Stable Baselines 3 (Raffin et al., 2021). La elección se justifica porque DQN está diseñado para espacios de acciones discretos, como el de CartPole. Como la observación es un vector numérico de dimensión cuatro y no una imagen, se utilizó `MlpPolicy`, es decir, una red neuronal totalmente conectada.

La red aproxima la función de valor de acción $Q(s, a)$. Para cada estado selecciona la acción con mayor valor estimado. La arquitectura utilizada contiene dos capas ocultas de 64 neuronas. De forma esquemática, la red recibe cuatro valores, los procesa mediante las dos capas ocultas y devuelve dos valores Q .

Configuración Experimental

El agente se entrenó durante 60.000 interacciones con el entorno. Los hiperparámetros utilizados se muestran en la Tabla 1.

Tabla 1: Configuración de DQN para CartPole-v1.

Parámetro	Valor
Política	<code>MlpPolicy</code>
Pasos de entrenamiento	60.000
Tasa de aprendizaje	10^{-3}
Tamaño del <i>buffer</i>	50.000
Inicio del aprendizaje	1.000 pasos
Tamaño de lote	64
Factor de descuento γ	0,99
Frecuencia de entrenamiento	4 pasos
Pasos de gradiente	1
Red objetivo	cada 500 pasos
Exploración ϵ	$1, 0 \rightarrow 0, 02$
Fracción de exploración	0,25

Durante el entrenamiento se empleó `EvalCallback`. Cada 1.000 pasos, el agente se evaluó durante 10 episodios deterministas en un entorno independiente del utilizado para aprender. Cuando la recompensa media superaba el mejor resultado anterior, el callback guardaba un nuevo punto de control en `best_model`. Al completar los 60.000 pasos también se almacenó el estado final del agente en `dqn_cartpole_final`. Esto permite diferenciar entre:

- **mejor checkpoint:** Parámetros correspondientes al mejor rendimiento observado durante las evaluaciones periódicas.
- **modelo final:** Parámetros existentes exactamente al terminar los 60.000 pasos.

Evolución del entrenamiento

La Figura 2 muestra la recompensa media obtenida en las evaluaciones periódicas. La línea continua representa la media de 10 episodios y la zona sombreada representa una desviación típica. La línea horizontal discontinua marca la recompensa máxima del entorno.




Figura 2: Evolución de la recompensa de DQN durante 60.000 pasos de entrenamiento. La zona sombreada representa $\pm$ una desviación típica entre los episodios de evaluación.

La evolución no fue monótona. El agente encontró durante las primeras etapas una política de rendimiento muy elevado, pero las actualizaciones posteriores redujeron su rendimiento y produjeron oscilaciones. Este resultado no implica que entrenar durante más pasos sea siempre perjudicial; muestra que, en este experimento, el último estado de la red no coincidió con la política de mejor rendimiento. Por ello fue necesario conservar y evaluar el mejor checkpoint.

La mejor evaluación periódica obtuvo una recompensa media de 495,2 sobre los 10 episodios empleados por el callback. Al evaluar posteriormente el checkpoint guardado sobre 30 nuevos episodios, este alcanzó la recompensa máxima de 500 en todos ellos.


Evaluación final y comparación de políticas

La política aleatoria, el mejor checkpoint y el modelo final se evaluaron sobre 30 episodios. Se utilizó inferencia determinista para los modelos DQN, de modo que durante la prueba se seleccionó siempre la acción con mayor valor Q , sin introducir exploración aleatoria. Para cada episodio se registraron la recompensa acumulada y si se alcanzaron los 500 pasos. Posteriormente, sobre el conjunto de 30 episodios, se calcularon la media, la desviación típica, el mínimo, el máximo y el porcentaje de éxito.

Los resultados se presentan en la Tabla 2 y en la Figura 3.

Tabla 2: Evaluación de las políticas en 30 episodios de CartPole-v1.

Política	Media	Desv. típica	Mínimo	Máximo	Episodios de 500	Éxito
Política aleatoria	21,07	8,79	10	42	0/30	0 %
Mejor checkpoint DQN	500,00	0,00	500	500	30/30	100 %
Modelo final DQN	227,13	11,90	208	256	0/30	0 %

**Figura 3:** Recompensa media de las tres políticas. Las barras de error representan una desviación típica.

La política aleatoria obtuvo una recompensa media de 21,07 y no completó ningún episodio. Su recompensa osciló entre 10 y 42, lo que indica que algunas secuencias fortuitas de acciones prolongan ligeramente el episodio, pero ninguna constituye una estrategia capaz de resolver el entorno. Sin embargo, las actualizaciones posteriores deterioraron una política que previamente había alcanzado un rendimiento óptimo.

El modelo final obtuvo una media de 227,13. Aunque no alcanzó los 500 pasos, su rendimiento fue muy superior al de la política aleatoria. Esto confirma que el agente sí aprendió una estrategia útil.

El mejor checkpoint obtuvo una recompensa de 500 en los 30 episodios, con desviación típica nula. Por tanto, mantuvo el péndulo en equilibrio durante todos los pasos disponibles en el 100 % de las ejecuciones evaluadas.

La comparación entre la política aleatoria y la política aprendida mediante DQN demuestra que el resultado no se debe a una secuencia afortunada de movimientos, sino a una estrategia capaz de reaccionar de forma coherente ante el estado del sistema.

Selección de la política y demostración visual

La política seleccionada para el ejercicio fue el mejor checkpoint de DQN, porque fue la única que alcanzó los 500 pasos en todos los episodios de evaluación. El modelo final no se eligió únicamente por ser el último

generado, ya que sus métricas muestran un rendimiento claramente inferior.

Para complementar la evaluación cuantitativa, se generaron dos vídeos que permiten comparar visualmente el comportamiento de las políticas. El primero muestra la política aleatoria, que pierde el equilibrio tras pocos pasos al seleccionar las acciones sin utilizar el estado del sistema. El segundo corresponde al mejor checkpoint de DQN y muestra un único episodio continuo que alcanza los 500 pasos y una recompensa total de 500.

Grabar un único episodio completo del agente entrenado evita concatenar distintos reinicios y permite comprobar que el equilibrio se mantiene durante todo el límite temporal del entorno. Ambos vídeos se incluyen en la carpeta `videos` del archivo comprimido entregado y también se encuentran disponibles en el repositorio de GitHub. Los nombres y enlaces se recogen en la Tabla 3.

Tabla 3: Material audiovisual asociado al experimento de CartPole-v1.

Política	Archivo incluido en la entrega	Acceso online
Política aleatoria	videos/cartpole_aleatorio.mp4	Abrir vídeo
Mejor checkpoint DQN	videos/cartpole_dqn_mejor.mp4	Abrir vídeo

Conclusiones del experimento

El ejercicio permitió comprobar tres aspectos relevantes. En primer lugar, la política aleatoria es incapaz de resolver `CartPole-v1`, ya que no utiliza la información del estado. En segundo lugar, DQN con una red neuronal pequeña es capaz de aprender una política que mantiene el equilibrio durante los 500 pasos. Finalmente, el entrenamiento mostró que el rendimiento puede fluctuar y que el último modelo no tiene por qué ser el mejor. La evaluación periódica, el uso de un entorno independiente y el guardado del mejor checkpoint fueron, por tanto, decisiones esenciales para seleccionar correctamente la política final.

Referencias

- Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533, 2015.
- Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268):1–8, 2021.
- Mark Towers, Ariel Kwiatkowski, Jordan Terry, John U. Balis, Gianluca De Cola, Tristan Deleu, Manuel Goulão, Andreas Kallinteris, Arjun Krimmel, et al. Gymnasium: A standard interface for reinforcement learning environments. *arXiv preprint arXiv:2407.17032*, 2024.